FCompiler: A FOOL implementation

Giulia Cantini Matteo Del Vecchio Simone Preite

$20~{\rm Luglio}~2018$

Indice

1	Introduzione		1
	1.1	Specifiche fornite	2
		1.1.1 Espressioni	2
		1.1.2 Comandi	2
		1.1.3 Object orientation	2
		1.1.4 Type check	3
		1.1.5 Il codice oggetto	3
		1.1.6 Opzionali	4
2	Str	uttura del progetto	4
3	Car	ratteristiche del linguaggio e grammatica	4
4	Ana	alisi lessicale e sintattica (AST)	6
	4.1	Nodi delle funzioni	7
	4.2	Nodi per la gestione delle classi	7
5	Analisi semantica 7		
	5.1	Symbol table	7
	5.2	Type check	9
6	Generazione del codice		11
	6.1	Gestione degli offset, stack, heap	11
		6.1.1 Implementazione del null	11
	6.2	Layout di un oggetto	11
	6.3	Grammatica SVM senza attributi e SVMVisitor	11
	6.4	Dynamic dispatch	13
7	Cor	nclusioni	13

1 Introduzione

Il progetto consiste nell'implementazione di un compilatore per il linguaggio FOOL (Functional Object Oriented Language) che traduce in bytecode esegui-

bile da una stack machine SVM (Simplified Virtual Machine).

Di seguito si riportano le specifiche fornite per il progetto.

1.1 Specifiche fornite

1.1.1 Espressioni

Estensione delle espressioni con operatori $\langle =, >=, ||, \&\&, /, -e \text{ not.}$

1.1.2 Comandi

Esiste la categoria sintattica stm:

```
stm : id = exp (assegnamento) ;
| if exp then stms else stms (condizionale)
stms : ( stm )+
```

1.1.3 Object orientation

E' possibile dichiarare classi e sottoclassi al top level. Le classi contengono

- campi (dichiarati nella classe o ereditati dalla super-classe)
- metodi (esplicitamente dichiarati nella classe o ereditati dalla super-classe).

Se in una sottoclasse viene dichiarato un metodo con il medesimo nome di un metodo della super-classe, tale metodo sovrascrive quello della super-classe. Non è possibile avere overriding di campi.

Quindi, significa che occorre estendere

dichiarazioni

In particolare

```
class ID [extends ID] (...campi dichiarati come parametri...)
... metodi dichiarati come funzioni ...

espressioni

x.m(..) // x è un oggetto, m è un metodo

new C(..) // C è un identificatore di classe

null

comandi con x.m(..), se il metodo ritorna void.
```

• Gli oggetti nascono come istanza di classi

- I campi sono modificabili
- Il linguaggio ha il comando di assegnamento
- Non è possibile dichiarare funzioni annidate. Le funzioni non possono essere passate come parametri
- E' possibile avere funzioni/metodi mutuamente ricorsivi.

1.1.4 Type check

Il compilatore deve comprendere un type-checker che controlli il corretto uso dei tipi. In particolare:

- Esiste il tipo void, oltre al tipo classe
- Si deve considerare una nozione di subtyping fra classi e tipi di funzioni. Il tipo di una funzione f1 è sottotipo del tipo di una funzione f2 se il tipo ritornato da f1 è sottotipo del tipo ritornato da f2, se hanno il medesimo numero di parametri, e se ogni tipo di parametro di f1 è sopratipo del corrisponde tipo di parametro di f2.
 - Una classe C1 è sottotipo di una classe C2 se C1 estende C2 e se i campi e metodi che vengono sovrascritti sono sottotipi rispetto ai campi e metodi corrispondenti di C2. Inoltre, C1 è sottotipo di C2 se esiste una classe C3 sottotipo di C2 di cui C1 è sottotipo.
- Definire e implementare le regole di tipaggio per tutti i costrutti, in particolare per il condizionale.

1.1.5 Il codice oggetto

Il compilatore deve generare codice per un esecutore virtuale chiamato SVM (stack virtual machine) la cui sintassi è definita nel file SVM.g. Tale esecutore ha una memoria in cui gli indirizzi alti sono usati per uno stack. Uno stack pointer punta alla locazione successiva alla prossima locazione libera per lo stack (se la memoria ha indirizzi da 0 a MEMSIZE-1, lo stack pointer inizialmente punta a MEMSIZE). In questo modo, quando lo stack non è vuoto, lo stack pointer punta al top dello stack.

Il programma è collocato in una memoria separata puntata dall'instruction pointer (che punta alla prossima istruzione da eseguire). Gli altri registri della macchina virtuale sono: HP (heap pointer), RA (return address), RV (return value) e FP (frame pointer).

In particolare, HP serve per puntare alla prossima locazione disponibile dello heap; assumendo di usare gli indirizzi bassi per lo heap, HP contiene inizialmente il valore 0.

- Implementare tutte le operazioni per le nuove espressioni
- Implementare il dynamic dispatch ==> implementare e definire layout oggetti e classi

• La generazione di codice oggetto è fatta utilizzando una grammatica con attributi, vedere SVM.g4). Definire una grammatica SENZA attributi (come FOOL.g4) e definire una visita dell'albero sintattico per generare il codice.

1.1.6 Opzionali

La deallocazione degli oggetti nello heap (garbage collection) non è obbligatoria.

2 Struttura del progetto

Il codice sorgente del progetto è contenuto nella sottodirectory source/ che è così divisa:

- ast/ contiene i nodi dell'albero di sintassi astratta utilizzati nell'implementazione della relativa visita
 - ast/types/ in particolare, contiene quei nodi che rappresentano dei tipi all'interno della grammatica
- grammars/ contiene i file .g4 per le grammatiche FOOL e SVM con i rispettivi parser e le implementazioni dei visitor per la visita dell'AST e del bytecode
- lib/ contiene i JAR delle libreria di ANTLRv4, di commons-cli per eseguire il progetto da riga di comando e la libreria YAML di supporto al testing
- testMain/ contiene le classi principali per l'esecuzione del progetto, ovvero le due configurazioni di run, Main. java per l'esecuzione standard con debug di un singolo programma FOOL, TestSuite. java per l'esecuzione dei test contenuti nel file testSuite.yml in formato YAML e CommandLineMain. java per l'esecuzione e la creazione del file JAR eseguibile da riga di comando.
- utils/ contiene le classi di supporto per la symbol table, il type checking, eccezioni personalizzate e altre funzioni ausiliarie (come quella per ordinare gli errori semantici secondo il numero di riga e colonna).

Il progetto è stato sviluppato usando **IntelliJ IDEA**; si consulti il file README .md per le istruzioni su come aprire ed eseguire il progetto con il suddetto IDE oppure utilizzando Eclipse o il terminale.

3 Caratteristiche del linguaggio e grammatica

Un tipico programma scritto in linguaggio FOOL è formato da un insieme di blocchi: ogni blocco può essere una dichiarazione di classe (al top level) oppure una sequenza di dichiarazioni introdotte dalla keyword let, seguite da un'altra sequenza di statement in cui le variabili dichiarate vengono usate, introdotta dalla keyword in.

```
class A (int x = 1, int y = 2) {
    void m() print(0);
}
let
    A a = new A();
in
    a.m();
```

Le espressioni sono state estese per comprendere gli operatori <=, >=, ||, &&, /, -e not nella seguente maniera:

```
exp
       : left=operand (operator=(EQ | LEQ | GEQ) right=exp)?;
operand : left=term (operator=(PLUS | MINUS) right=operand)? ;
       : left=factor (operator=(TIMES | DIV) right=term)?;
factor : left=atom (operator=(OR | AND) right=factor)?;
       : (NOT)? (MINUS)? val=value ;
atom
value
       : INTEGER
                                   #intVal
       BOOLVAL
                                   #boolVal
       NULL
                                   #nullVal
       | LPAR exp RPAR
                                   #baseExp
       var
                                  #varExp
       | IF LPAR cond=exp RPAR THEN CLPAR thenBranch=exp CRPAR ELSE CLPAR
    elseBranch=exp CRPAR #ifExp
       | ID (LPAR (exp (COMMA exp)*)? RPAR) #funExp
       | object=var DOT memberName=ID (LPAR (exp (COMMA exp)* )? RPAR)?
    methodExp
       | NEW className=ID (LPAR RPAR) #newExp
       ;
```

Sono stati aggiunti gli statement

Uno statement può essere un assegnamento (semplice o a campo di un oggetto), un condizionale, una print o una chiamata di funzione/metodo.

Una dichiarazione di classe viene fatta nel modo seguente:

```
class hero {
    bool iAmBatman() return true;
};

class super extends hero(int x = 0, bool cond = true) {
    int fun() return 1;
    int soMuchFun(int a, bool b) return 1000;
};
```

dove le parentesi tonde delimitano i campi e le parentesi graffe i metodi. Una classe può contenere nessun campo ma deve contenere sempre almeno un metodo. Una classe può estenderne un'altra (di cui diventerà una sottoclasse), ereditandone campi e metodi, utilizzando la keyword extends.

```
classdec : CLASS className=ID ( EXTENDS superName=ID )? (LPAR varasm (COMMA
    varasm)* RPAR)? CLPAR (fundec SEMIC)+ CRPAR ;
```

Un oggetto può essere istanziato utilizzando la keyword new. Il costruttore deve essere richiamato senza argomenti, mentre i valori dei campi sono stati già inizializzati durante la dichiarazione della classe e potranno essere modificati successivamente tramite assegnamento.

Ulteriori caratteristiche del linguaggio sono le seguenti:

- Tutte le variabili devono essere inizializzate al momento della dichiarazione (così come vale per i campi di una classe).
- Una variabile può avere tipo intero, booleano o classe (se è un oggetto).
- Una funzione può avere tipo di ritorno void
- E' stato inserito il tipo null che è sottotipo di classe, per consentirne l'assegnamento ad un oggetto.
- Una funzione può opzionalmente avere un blocco let in all'interno del suo body, che è formato da soli statement, 0 o più statement seguiti da un'espressione di ritorno oppure un'espressione preceduta dalla keyword return nel caso in cui il suo tipo di ritorno sia diverso da void.

4 Analisi lessicale e sintattica (AST)

L'interfaccia Node, implementata da tutti i nodi dell'AST è stata modificata nel seguente modo:

• il metodo checkSemantics() ha come tipo di ritorno HashSet<String> invece di ArrayList<Semantic Error>; l'oggetto di tipo String rappresenta la stringa che contiene l'errore semantico e si è optato per una gestione degli errori con HashSet per facilitare il controllo sull'inserimento di duplicati.

- il metodo typeCheck() adesso solleva un'eccezione quando viene rilevato un errore di tipo (vedi file source/utils/TypeCheckException.java).
- E' stato aggiunto il metodo getID() che restituisce l'identificatore di un oggetto, o di un generico nodo, sotto forma di stringa.

4.1 Nodi delle funzioni

- FunDecNode rappresenta la dichiarazione di una funzione, in esso sono memorizzati il nome della funzione, il suo tipo di ritorno, la lista dei parametri, la lista delle dichiarazioni e il corpo della funzione. Inoltre il nodo memorizza l'entry della symbol table associata alla funzione stessa.
- FunExpNode rappresenta l'invocazione di una funzione, in esso sono memorizzati l'ID della funzione, gli argomenti, il nesting level e una variabile di supporto classID per gestire la chiamata di metodo che avviene senza dot notation (all'interno di un altro metodo). Inoltre il nodo memorizza l'entry della symbol table associata alla funzione stessa.

4.2 Nodi per la gestione delle classi

- BlockClassDecNode rappresenta la dichiarazione di una classe; contiene, oltre ai metodi implementati dell'interfaccia Node, le funzioni ausiliarie getMethods() e getFields()
- ClassMethodNode rappresenta la chiamata di metodo (o.m()); è sottoclasse di FunExpNode
- ClassFieldNode rappresenta il campo di una classe
- MethodDecNode rappresenta la dichiarazione di metodo
- ClassType rappresenta il tipo classe, memorizza l'ID, l'ID dell'eventuale superclasse, la lista dei campi e dei metodi. Contiene getter e setter per gestire questi campi.

5 Analisi semantica

5.1 Symbol table

La costruzione della symbol table avviene visitando l'AST e richiamando su un ogni nodo il metodo checkSemantics() che, a partire dal primo nodo ProgNode (rappresentante la start rule della grammatica FOOL.g4) viene richiamata due volte. Le due visite successive servono per la gestione delle dichiarazioni di classi e di funzioni/metodi.

Nel caso delle dichiarazioni di classi, la prima passata viene utilizzata per racco-gliere tutte le dichiarazioni, mentre la seconda serve per gestire campi, metodi, oggetti e risolvere le relazioni di sottotipaggio tra classi.

Nel caso di funzioni/metodi, la doppia visita consente di implementare il meccanismo di mutua ricorsione, ovvero consente che nel corpo di una funzione possa

essere chiamata un'altra funzione non ancora definita. Lo stesso vale per i metodi.

La tabella dei simboli viene gestita utilizzando la classe Environment (contenuta nella sottodirectory utils) e i metodi di supporto che essa contiene. La classe contiene i seguenti campi:

In più contiene (oltre a getter e setter per i campi) anche i metodi:

- public int decreaseOffset()
- public int increaseOffset()
- public SymbolTableEntry getActiveDec(String id)
 Scorre la symbol table alla ricerca della entry corrispondente alla dichiarazione al momento attiva nell'ambiente, per l'oggetto rappresentato da
 ID.
- public void pushScope()
 Aggiunge una nuova tabella hash alla lista che rappresenta la symbol table,
 con nesting level incrementato. In altre parole ciò avviene quando si entra
 in un nuovo scope.
- public void popScope()
 Rimuove dalla symbol table la hash corrispondente al nesting level corrente, e poi lo decrementa.
- public SymbolTableEntry getClassEntry(String classID)

 Cerca nella symbol table la entry della classe rappresentata da classID

La tabella dei simboli viene riempita utilizzando la classe SymbolTableEntry che possiede i seguenti campi:

```
private int nestingLevel;
private int offset;
private Node type; // nel caso degli oggetti, indica il tipo dinamico
private String className; // usata nel caso di entry che rappresentano classi
private Node staticType; // usata nel caso di classi
```

5.2 Type check

I tipi su cui si basa il sistema di tipaggio di FOOL sono i seguenti:

- BoolType
- ClassType
- FunType
- IntType
- NullType
- VoidType

Il sottotipaggio viene controllato utilizzando la funzione

• public static boolean subtypeOf(Node a, Node b)

che restituisce true se il nodo a è sottotipo del nodo b (in Helpers). In particolare, bool è sottotipo di int, void è sottotipo di classe, mentre una classe è sottoclasse di un'altra se intersecando la lista delle superclassi della prima con la lista delle superclassi della seconda si ottiene un insieme non vuoto.

Il sottotipaggio tra funzioni/metodi viene gestito all'interno delle typeCheck() di FunDecNode e MethodDecNode: come da specifica, il controllo viene eseguito su tipo di ritorno e tipi e numero dei parametri per verificare che i tipi delle funzioni siano compatibili.

Si sono implementate le regole di tipaggio per tutti i costrutti:

• costanti intere

$$\frac{x \text{ is an } int \text{ token}}{\vdash x : int} [IntVal]$$

 $\bullet\,$ costanti booleane

$$\frac{}{\vdash true:bool}[BoolVal_1] \qquad \frac{}{\vdash false:bool}[BoolVal_2]$$

• operatori logici e relazionali

$$\begin{split} \frac{\Gamma \vdash e:bool}{\vdash not \; e:bool}[Not] \\ \frac{\Gamma \vdash e_1:bool}{\Gamma \vdash e_1:bool} \frac{\Gamma \vdash e_2:bool}{\Gamma \vdash e_1 \&\& \; e_2:bool}[And] & \frac{\Gamma \vdash e_1:bool}{\Gamma \vdash e_1 \mid\mid e_2:bool}[Or] \\ \frac{\Gamma \vdash e_1:T_1 \quad \Gamma \vdash e_2:T_2 \quad T_1 <: T \quad T_2 <: T}{\Gamma \vdash e_1:int \quad \Gamma \vdash e_2:int}[Equal] \\ \frac{\Gamma \vdash e_1:int \quad \Gamma \vdash e_2:int}{\Gamma \vdash e_1:e_2:bool}[LessEqual] & \frac{\Gamma \vdash e_1:int \quad \Gamma \vdash e_2:int}{\Gamma \vdash e_1:bool}[GreaterEqual] \end{split}$$

• operatori aritmetici

$$\frac{\Gamma \vdash e_1 : int \qquad \Gamma \vdash e_2 : int}{\Gamma \vdash e_1 + e_2 : int} [Plus] \qquad \frac{\Gamma \vdash e_1 : int \qquad \Gamma \vdash e_2 : int}{\Gamma \vdash e_1 - e_2 : int} [Sub]$$

$$\frac{\Gamma \vdash e_1 : int \qquad \Gamma \vdash e_2 : int}{\Gamma \vdash e_1 \times e_2 : int} [Times] \qquad \frac{\Gamma \vdash e_1 : int \qquad \Gamma \vdash e_2 : int}{\Gamma \vdash e_1 / e_2 : int} [Div]$$

$$\frac{\Gamma \vdash e_1 : int}{\Gamma \vdash (-e_1) : int} [UnaryMinus]$$

• condizionale

$$\begin{split} \frac{\Gamma \vdash c : bool \quad \Gamma \vdash e_1 : T_1 \quad \Gamma \vdash e_2 : T_2 \quad T_2 <: T_1}{\Gamma \vdash if \quad (c) \quad then \quad e_1 \quad else \quad e_2 : T1} [IfExp_1] \\ \frac{\Gamma \vdash c : bool \quad \Gamma \vdash e_1 : T_1 \quad \Gamma \vdash e_2 : T_2 \quad T_1 <: T_2}{\Gamma \vdash if \quad (c) \quad then \quad e_1 \quad else \quad e_2 : T2} [IfExp_2] \\ \frac{\Gamma \vdash c : bool \quad \Gamma \vdash s_1 : T_1 \quad \Gamma \vdash s_2 : T_2 \quad T_1 <: void \quad T_2 <: void}{\Gamma \vdash if \quad (c) \quad then \quad s_1 \quad else \quad s_2 : void} [IfStm] \end{split}$$

• variabili

$$\frac{}{\Gamma[x \to T] \vdash x : T}[Var]$$

• print

$$\frac{\Gamma \vdash e_1: T_1, ..., e_n: T_n \qquad T_1, ..., T_n \ ! = void}{\Gamma \vdash print(e_1, ..., e_n): void} [Print]$$

- chiamata di funzione (con subtyping)
- accesso ad un campo

$$\frac{\Gamma \vdash o : C \qquad C \vdash x : T}{\Gamma \vdash o . x : T} [Field]$$

• istanziazione di un oggetto (new)

$$\frac{\Gamma \vdash new \ C:() \to C}{\Gamma \vdash new \ C():C}[New]$$

• assegnamento

$$\frac{\Gamma(x) = T_1 \qquad \Gamma \vdash e : T_2 \qquad T_2 <: T_1}{\Gamma \vdash x = e : void} [Assignment]$$

• comandi

$$\frac{\Gamma \vdash stm : void}{\Gamma \vdash stm; stms : void} [SeqStms]$$

6 Generazione del codice

- 6.1 Gestione degli offset, stack, heap
- 6.1.1 Implementazione del null
- 6.2 Layout di un oggetto

6.3 Grammatica SVM senza attributi e SVMVisitor

Il progetto di base forniva una grammatica, SVM.g4, già implementata per la generazione del codice oggetto. Essa però conteneva attributi, ovvero particolare azioni in Java da effettuare nel momento in cui un determinato token sarebbe stato matchato con l'input.

Come richiesto dalle specifiche del progetto, è stata implementata una visita per la generazione del codice, trasformando la grammatica fornita in una senza attributi. Sebbene quella iniziale fosse semplice, è stato ritenuto opportuno modificarla in modo radicale per favorire una migliore gestione della visita sull'AST generato.

Il risultato è il seguente:

Rispetto alla grammatica di partenza, sono state introdotte le seguenti istruzioni assembly che hanno quindi richiesto la modifica del file ExecuteVM. java:

• NEW

Si occupa dell'istanziazione di un oggetto nell'heap. L'istruzione assume di avere sulla testa dello stack l'indirizzo della Dispatch Table relativa al tipo dell'oggetto in questione, il numero di campi ed i relativi valori. Il risultato consiste nella creazione dell'oggetto nell'heap e nella restituzione, sulla testa dello stack, dell'indirizzo di tale oggetto.

• CPHEAD

Semplice istruzione che si occupa di duplicare il valore presente sulla testa dello stack. Viene utilizzato durante la code generation dei metodi di un oggetto.

• JSMETH

Pusha sullo stack l'indirizzo della prima istruzione del metodo invocato, in modo da usare successivamente l'istruzione JS per l'esecuzione dello stesso.

Inoltre, sono stati aggiunti i seguenti campi al Parser SVM:

```
public static int[] code = new int[ExecuteVM.CODESIZE];
static int i = 0;
static HashMap<String,Integer> labelAdd = new HashMap<String,Integer>();
static HashMap<Integer,String> labelRef = new HashMap<Integer,String>();
static void resetSVM() {
   code = new int[ExecuteVM.CODESIZE];
   i = 0;
   labelAdd = new HashMap<String,Integer>();
   labelRef = new HashMap<Integer,String>();
}
```

L'implementazione della visita è presente nel file SVMVisitorImpl.java e, per poter accedere alle suddette variabili del parser, sono state dichiarate in modo statico. Per questo motivo però, è stato necessario creare il metodo resetSVM(), in modo da azzerare il contenuto della macchina virtuale ogni qual volta venga eseguito un programma (come ad esempio nel caso dei test, i quali sono valutati automaticamente uno dopo l'altro).

L'idea alla base della nostra implementazione della visita è costituita dall'uso di tre regole per il parser e dei relativi metodi di visita:

```
public Void visitAssembly(AssemblyContext ctx);
public Void visitSimpleCmd(SimpleCmdContext ctx);
public Void visitComposedCmd(ComposedCmdContext ctx);
```

visitAssembly() rappresenta il punto d'inizio della visita dell'intero AST, gestisce il reset della macchina virtuale e la trasformazione delle label in opportuni interi; inoltre, utilizzando questo approccio, ci è stato facile ricavare il numero totale di nodi su cui ciclare per riempire l'array contenente il codice. visitSimpleCmd() gestisce tutte le istruzioni assembly semplici, che non hanno parametri, in quanto la loro semantica consiste solo nell'aggiunta dell'opportuno codice istruzione nell'array code.

Infine, visitComposedCmd() gestisce le istruzioni assembly che necessitano di più operazioni oltre alla semplice memorizzazione del codice istruzione; in particolare, si tratta di operazioni relative alla creazione/associazione delle label nel codice.

La visita e la generazione del codice da far eseguire alla macchina virtuale avviene con il seguente codice:

```
// si assume che input sia un CharStream contenente il testo da parsare
SVMLexer asmLexer = new SVMLexer(input);
CommonTokenStream asmTokens = new CommonTokenStream(asmLexer);
SVMParser asmParser = new SVMParser(asmTokens);
SVMVisitorImpl asmVisitor = new SVMVisitorImpl();
asmVisitor.visit(asmParser.assembly());
```

Per migliorare il risultato dell'esecuzione della macchina virtuale, il file ExecuteVM . java è stato ulteriormente modificato in modo da individuare la divisione per

zero e l'accesso ad un oggetto nullo (tramite le eccezioni custom DivisionByZeroException e NullObjectException).

Attraverso due ArrayList di stringhe, outputBuffer e errorBuffer, la macchina virtuale restituisce il proprio output, come mostrato nel codice seguente (continuazione di quello precedente):

```
ExecuteVM vm = new ExecuteVM(SVMParser.code);
vm.cpu();
if (!vm.errorBuffer.isEmpty()) {
    if (verbose) result.append("Some errors occurred during execution:\n");
    for (String e: vm.errorBuffer)
        result.append(e).append("\n");
}
else {
    if (verbose) result.append("Virtual Machine execution result:\n");
    if (vm.outputBuffer.size() == 0)
        result.append("Execution completed. No output shown.\n");
    else
        for (String res: vm.outputBuffer)
            result.append(res).append("\n");
}
```

6.4 Dynamic dispatch

7 Conclusioni